



MDA Online — Sesión 2

Diseño e Implantación de Soluciones GenAI

Alberto Cámara · ISDI MDA Online · 6 de mayo de 2026

<> Agenda — MDA Online Sesión 2

Primera parte (~75 min)

- Demo de apertura: **Ollama**
- Un chatbot de atención al cliente: ¿qué puede salir mal?
- Casos de uso por función de negocio
- Arquitectura RAG a fondo
- Model-agnosticity: Gemini vs. Ollama
- Demo en vivo: RAG sobre reviews (extendida)

Segunda parte (~75 min)

- Build vs. Buy
-  **Sección crítica:** gobierno del dato y lock-in
- Human-in-the-loop
- Demo extendida + Q&A

Primera parte

Casos de uso, RAG y modelo de referencia

<> ¿Qué falló aquí?

Caso real: una aerolínea despliega un chatbot de atención al cliente basado en un LLM.

El chatbot inventa una política de reembolso que no existe.

Un pasajero la cita en un litigio.

La aerolínea pierde el caso en los tribunales.

Air Canada, 2024. El tribunal dictaminó que la empresa era responsable de la información incorrecta generada por su chatbot (fuente: [The Guardian](#)).

<> ¿Qué falló aquí? — El diagnóstico

¿Por qué sucedió?

- El LLM no tenía acceso a las políticas actuales de la empresa
- Generó respuestas plausibles a partir de su entrenamiento general
- Sin mecanismo de verificación ni supervisión humana

El problema no fue el LLM. Fue el diseño del sistema: conectar un modelo de propósito general a un dominio que requería información específica, privada y actualizada.

<> **Cómo Identificar un Buen Caso de Uso**

Señales positivas

- Tarea repetitiva y bien definida
- La calidad actual depende de un humano sobrecargado
- El error tiene coste bajo o es recuperable
- Existe suficiente dato histórico para evaluar el output

Señales de alerta

- Decisiones con impacto legal, médico o financiero directo
- Sin mecanismo de supervisión ni logging
- El dominio cambia frecuentemente (la información se queda obsoleta)

<> Casos de Uso: Marketing y Ventas

Tarea	Valor	Riesgo
Generación de copias para campañas	Alto — escala inmediata	Bajo (revisión humana trivial)
Personalización de emails	Alto — conversión +15–30%	Medio (datos personales)
Análisis de sentimiento de reviews	Alto — operacional	Bajo
Resumen de llamadas de ventas	Medio — ahorro de tiempo	Medio (datos de clientes)

<> Casos de Uso: Finanzas y Legal

Tarea	Valor	Riesgo
Resumen de informes financieros	Alto — decisiones más rápidas	Medio (datos confidenciales)
Revisión de contratos (flag de cláusulas)	Alto — reduce horas de abogado	Alto (decisiones jurídicas)
Detección de anomalías en transacciones	Alto — fraude	Alto (falsos positivos)
Generación de borradores legales	Medio	Muy alto — requiere validación total

En finanzas y legal, el LLM **asiste**; nunca decide solo. Human-in-the-loop no es opcional.

<> Casos de Uso: Atención al Cliente

El dominio donde el ROI se demuestra más rápidamente:

- **Clasificación y routing** de tickets → reducción de tiempo medio de respuesta
- **Respuesta automática** a consultas frecuentes → desescalada del volumen
- **Resumen de historial** antes de transferir a agente humano
- **Detección de urgencia** (clientes en riesgo de baja)

Este es el hilo conductor del curso: las reviews de electrónica simulan el dominio de atención al cliente. Hoy construimos el sistema que los agentes de la Sesión 3 usarán como memoria.

<> RAG: ¿Por Qué No Fine-Tuning?

El problema del conocimiento corporativo privado

Los LLMs se entrenan con datos públicos hasta una fecha de corte.
No conocen vuestros productos, precios, políticas ni historial.

Estrategia	Tiempo	Coste	Conocimiento actualizable
Fine-tuning	Semanas	\$1.000–\$50.000	No — hay que reentrenar
Prompting con contexto	Minutos	Bajo	Sí — pero limitado por contexto
RAG	Días	Medio	Sí — la base de datos se actualiza

⌞ RAG: Pipeline — Ingesta y Chunking

Fase offline (se ejecuta una vez, o cuando cambian los datos)

Documentos originales

↓ chunking (dividir en fragmentos manejables)

Chunks de texto

↓ embedding (convertir a vectores)

Vectores

↓ indexar

Base de datos vectorial (ChromaDB)

⌞ RAG: Pipeline — Retrieval y Generación

Fase online (ocurre con cada consulta del usuario)

Pregunta del usuario

↓ embedding de la pregunta

Vector de la pregunta

↓ búsqueda por similitud (top-k)

Chunks relevantes recuperados

↓ inyectar en el prompt como contexto

Prompt aumentado

↓ LLM genera respuesta

Respuesta fundamentada en los datos

<> RAG: Métricas de Calidad

Métrica	Qué mide	Cómo evaluarla
Faithfulness	¿La respuesta está soportada por el contexto recuperado?	LLM-as-judge o anotación humana
Answer relevance	¿La respuesta responde a la pregunta?	LLM-as-judge
Context precision	¿Los chunks recuperados son los correctos?	Dataset de evaluación
Context recall	¿Se recuperan todos los chunks necesarios?	Dataset de evaluación

Librería de referencia: **RAGAS** — automatiza la evaluación de pipelines RAG con estas métricas.

<> Model-Agnosticity: Un Principio de Diseño

El pipeline RAG es independiente del proveedor del LLM

LangChain abstrae el modelo con una interfaz común:

```
# Gemini (cloud, API key)  
llm = ChatGoogleGenerativeAI(model="gemini-2.5-flash")  
  
# Qwen en local (sin API key, sin coste por token)  
llm = ChatOllama(model="qwen3:4b")  
  
# El resto del pipeline no cambia  
rag_chain = retriever | prompt | llm | parser
```

<> Demo en Vivo: RAG sobre Reviews de Electrónica

`demo_rag_productos.ipynb`

Lo que vamos a hacer

1. Cargar 300 reviews del dataset de Amazon Electronics
2. Indexarlas en ChromaDB (con embeddings de Gemini)
3. Hacer preguntas en lenguaje natural
4. Comparar respuestas con y sin RAG
5. Evaluar faithfulness: ¿las respuestas están soportadas por el contexto?
6. Explorar edge cases: preguntas sin respuesta en el catálogo

→¹⁵ *Cambiar a notebook*

Segunda parte

Estrategia de implantación y gobierno

<> Build vs. Buy: Los Criterios

Construir internamente tiene sentido cuando:

- Los datos son sensibles y no pueden salir de la organización
- La tarea es tan específica que ningún producto del mercado encaja
- Tenéis capacidad técnica interna para mantenerlo

Comprar (SaaS / API) tiene sentido cuando:

- La velocidad de llegada al mercado es crítica
- El volumen no justifica el coste de infraestructura propia
- La tarea es genérica y un proveedor ya la resuelve bien

<> Build vs. Buy: La Decisión en la Práctica

Preguntas clave

1. ¿Cuánto tiempo podemos permitirnos tardar?
2. ¿Qué nivel de personalización necesitamos?
3. ¿Qué pasa si el proveedor sube precios un 3x?
4. ¿Qué datos vamos a enviar fuera?
5. ¿Tenemos equipo para mantenerlo?

Regla práctica

Empieza siempre con una API externa para validar el caso de uso. Migra a infraestructura propia solo si el volumen o la sensibilidad de datos lo justifica.

<> Gobierno del Dato: ¿Qué Pasa con tus Datos?

Cuando llamas a la API de un LLM externo:

- Los datos viajan a los servidores del proveedor (EE.UU., generalmente)
- Los ToS determinan si se usan para mejorar el modelo — leedlos
- OpenAI, Google y Anthropic ofrecen acuerdos de datos empresariales (no usar para entrenamiento), pero tienen coste adicional
- Los logs de las peticiones pueden retenerse durante meses

Regla práctica: Nunca envíes a una API externa datos que no publicarías en tu web corporativa, a menos que tengas un DPA firmado y hayas verificado la jurisdicción.

➤ Gobierno del Dato: GDPR y Jurisdicción

Situación	Implicación GDPR
Datos de clientes europeos → API en EE.UU.	Requiere cláusulas contractuales estándar (SCCs)
Emails de empleados en el prompt	Puede ser dato personal — requiere base legal
Reviews públicas de usuarios	Normalmente OK si están anonimizadas
Historial médico o financiero	Alto riesgo — considerar procesamiento local



Sección Crítica

Dependencia de proveedor y concentración de poder

⌞ Lock-In Tecnológico: El Riesgo Real

¿Qué es el lock-in en IA generativa?

- Prompts optimizados para el comportamiento específico de un modelo
- Formatos de respuesta que asumes en tu código
- Infraestructura y herramientas construidas alrededor de un proveedor
- Datos de evaluación generados por ese modelo

Casos documentados

- OpenAI deprecó GPT-3.5 Turbo en 2024 — usuarios tuvieron que migrar con urgencia
- Cambios de precios de 2×–4× sin previo aviso largo en distintos proveedores
- Cambios de comportamiento del modelo entre versiones que rompen pipelines

⌞ Lock-In Tecnológico — Geopolítica

La concentración es real

Tres empresas (Microsoft/OpenAI, Google, Anthropic) controlan la mayoría del mercado de LLMs de frontera.

Todas son estadounidenses.

Las restricciones de exportación de chips hacia China muestran que los gobiernos ya tratan esta tecnología como activo estratégico.

Implicaciones para Europa

- Iniciativas de soberanía: Mistral (Francia), Aleph Alpha (Alemania)
- El EU AI Act obliga a transparencia, pero no a soberanía de datos
- Sectores regulados (banca, salud) tienen restricciones adicionales

El riesgo geopolítico no es hipotético: si mañana EE.UU. restringe el acceso a APIs de IA para ciertas jurisdicciones, ¿qué parte de vuestro negocio se detiene?

<> Human-in-the-Loop: Por Qué Sigue Siendo Necesario

El modelo no sabe lo que no sabe

- No detecta cuándo su output es incorrecto
- No conoce el contexto de negocio que no está en el prompt
- No tiene responsabilidad legal ni reputacional

Ejemplos donde la supervisión humana es crítica

- Respuestas a clientes de alto valor
- Decisiones con impacto en empleo o crédito
- Contenido que será publicado con el nombre de la empresa
- ²⁴ Cualquier output en entornos regulados

<> Human-in-the-Loop: Cuándo Automatizar Completamente

La automatización total funciona cuando:

- El dominio está perfectamente acotado (preguntas FAQ)
- Hay un sistema de feedback que detecta errores automáticamente
- El coste de un error es bajo y recuperable
- El volumen hace que la supervisión humana sea económicamente inviable

Diseña siempre con un "escape hatch": el usuario siempre debe poder escalar a un humano. No es solo buena práctica — en algunos contextos (servicios financieros, salud) es requisito legal.

<> Demo Extendida + Q&A

Seguimos con `demo_rag_productos.ipynb`

Experimentos adicionales en vivo:

- ¿Qué pasa si preguntamos algo que no está en el catálogo?
- Ajustamos `top_k` de 3 a 10: ¿mejora la respuesta? ¿o añade ruido?
- Forzamos una pregunta ambigua — el modelo tiene que gestionar la incertidumbre
- Swap final a Ollama: mismo pipeline, sin coste por token, sin datos que salen

Q&A abierta: traed preguntas sobre diseño de casos de uso en vuestro sector.



¿Preguntas?

Próxima sesión:

MDA Online Sesión 3 — IA de Agentes, LangGraph, orquestación multi-agente y transformación organizativa